

Encontros Universitários 2024

Refatoração de code smells em Projetos Open Source Python - Clean Lab

Francisco Werley da Silva, Camile Isidorio Araújo

ENCONTROS
UNIVERSITÁRIOS 2024

SABERES
ILUMINAM

UFC 70

 UFC

Caracterização do Projeto

- Baseada na abordagem **Data-Centric AI**, focada na melhoria da qualidade dos dados.
- Detecta automaticamente problemas em conjuntos de dados:
 - Erros de rotulação (label errors);
 - Outliers;
 - Duplicatas;
 - Inconsistências.
- Compatível com frameworks como **PyTorch, TensorFlow, Keras, Hugging Face, XGBoost e Scikit-learn**.
- Suporta diferentes tipos de dados: texto, imagens, áudio e dados tabulares.
- **Objetivo:** melhorar o desempenho de modelos de aprendizado de máquina por meio da qualidade dos dados, sem modificar a arquitetura ou o algoritmo do modelo.

Métricas do Randon

Complexidade Ciclomática por Arquivo Antes da Refatoração

arquivo	funções	cc_media	cc_max	cc_soma	pior_rank	pior_funcao
cleanlab/token_classification/summary.py	3	16.67	25	50	D	commom_label_issues
cleanlab/token_classification/filter.py	1	13.0	13	13	C	find_label_issues
cleanlab/classification.py	10	11.9	41	119	F	find_label_issues
cleanlab/internal/validation.py	6	9.5	25	57	D	<u>assert_valid_inputs</u>
cleanlab/segmentation/summary.py	4	9.25	20	37	C	display_issues

Complexidade Ciclomática por Arquivo Depois da Refatoração

arquivo	funções	cc_media	cc_max	cc_soma	pior_rank	pior_funcao
cleanlab/token_classification/filter.py	1	13.00	13	13	C	find_label_issues
cleanlab/benchmarking/noise_generation.py	5	9.00	19	45	C	generate_noise_matrix_from_trace
cleanlab/datalab/internal/issue_finder.py	10	8.90	24	89	D	get_available_issue_types
cleanlab/segmentation/summary.py	6	6.50	14	39	C	common_label_issues
cleanlab/segmentation/rank.py	3	6.33	7	19	B	_get_label_quality_per_image

Complexidade Ciclomática por Função Antes da Refatoração

arquivo	tipo	nome	rank_cc	complexity
cleanlab/filter.py	function	find_label_issues	F	60
cleanlab/classification.py	method	find_label_issues	F	41
cleanlab/classification.py	method	fit	E	37
cleanlab/internal/multiannotator_utilities.py	function	asset_valid_pred_probs	D	26
cleanlab/rank.py	function	get_label_quality_ensemble_scores	D	26

Complexidade Ciclômática por Função Depois da Refatoração

arquivo	tipo	nome	rank_cc	complexity
cleanlab/datalab/internal/issue_finder.py	method	get_available_issue_types	D	24
cleanlab/benchmarking/noise_generation.py	function	generate_noise_matrix_from_trace	C	19
cleanlab/datalab/internal/issue_finder.py	function	_resolve_required_args_for_classification	C	17
cleanlab/filter.py	function	_find_label_issues_multiclass	C	16
cleanlab/token_classification/summary.py	function	_display_token_issue	C	16

Índice de Manutenibilidade Antes da Refatoração

arquivo	mi	rank_mi
cleanlab/internal/neighbor/knn_graph.py	27.4178	A
cleanlab/multiannotator.py	30.291	A
cleanlab/internal/token_classification_utils.py	32.1771	A
cleanlab/classification.py	33.5382	A

Índice de Manutenibilidade Depois da Refatoração

arquivo	mi	rank_mi
cleanlab/classification.py	23.4256	A
cleanlab/internal/neighbor/knn_graph.py	27.4178	A
cleanlab/multiannotator.py	29.3970	A
cleanlab/internal/token_classification_utils.py	32.1771	A
cleanlab/internal/multilabel_scorer.py	37.1111	A

Métricas brutas Antes da Refatoração

- LOC TOTAL: 25623
- LLOC TOTAL: 8369
- SLOC TOTAL: 12418
- COMMENTS TOTAL: 1083
- MULTI: 8021

Métricas brutas Depois da Refatoração

- LOC TOTAL: 27040
- LLOC TOTAL: 8851
- SLOC TOTAL: 13625
- COMMENTS TOTAL: 970
- MULTI: 8021

CodeCarbon

Antes da Refatoração

- **DURATION:** 14.152264899923466
- **EMISSIONS:** 3.105878839183592e-06
- **EMISSIONS_RATE:** 2.1946160993639884e-07
- **CPU_ENERGY:** 1.0383791834454802e-05
- **RAM_ENERGY:** 2.1196706388016336e-05
- **ENERGY_CONSUMED:** 3.1580498222471145e-05


Depois da Refatoração

- **DURATION:** 17.218359899998177
- **EMISSIONS:** 4.505636301842367e-06
- **EMISSIONS_RATE:** 2.6167627625456034e-07
- **CPU_ENERGY:** 2.0408325088940168e-05
- **RAM_ENERGY:** 2.540487194447551e-05
- **ENERGY_CONSUMED:** 4.581319703341569e-05

PyLint


Distribuição do Smells Antes da Refatoração:

Distribuição code smells



Distribuição do Smells Depois da Refatoração:


Distribuição dos code smells após refatoração



Distribuição dos Problemas de Código Antes da Refatoração:



Distribuição dos Problemas de Código Depois da Refatoração:




Arquivos Mais Críticos Antes da Refatoração:

Distribuição arquivos críticos

Arquivo	Convention	Refactor	Warning	Error	Total	Total (gráfico)
multiannotator.py	184	29	13	7	233	233
count.py	114	13	9	0	136	136
object_detection/rank.py	97	16	18	0	131	131
regression/learn.py	92	16	5	2	115	115
object_detection/summary.py	91	9	12	1	113	113
filter.py	70	11	14	3	98	98
classification.py	74	14	9	0	97	97
outlier.py	90	2	2	2	96	96
experimental/label_issues_batched.py	71	13	4	0	88	88
datalab/datalab.py	68	2	1	0	71	71
Totais gerais	951 Convention	125 Refactor	87 Warning	15 Error	1178 Total geral	

Arquivos Mais Críticos Depois da Refatoração:

Distribuição dos 10 arquivos mais críticos após refatoração




Score do Projeto

Antes da refatoração:

6.20/10

Depois da refatoração:

6.41/10



Pytest

Testes Passaram vs Testes Falharam

Antes da refatoração:

Quantidade de testes que passaram: 1077

Quantidade de testes que falharam: 2

Depois da refatoração:

Quantidade de testes que passaram: 1063

Quantidade de testes que falharam: 18

Conclusões

- As refatorações contribuíram para melhorar a organização interna do código, reduzindo a concentração de responsabilidades em funções e classes muito complexas.
- Apesar de nem todos os problemas terem sido eliminados, a atividade mostrou que a refatoração é importante para tornar o projeto mais legível, manutenível e preparado para futuras contribuições.
- Também foi possível perceber que o uso de LLMs pode ajudar na identificação e sugestão de melhorias, mas as alterações ainda precisam ser revisadas e validadas por testes para garantir que o comportamento do sistema seja preservado.

OBRIGADO!

ENCONTROS
UNIVERSITÁRIOS **2024**

SABERES
QUE
ILUMINAM

UFC 

